

**MBA
USP
ESALQ**

Exploração do Padrão de Gastos de Deputados Federais com Cota Parlamentar por Clusterização

Dalciana Bressan Waller
Eder Costa Cassettari

Introdução

Contexto

- Deputados federais contam com diversos apoios financeiros tais como: remuneração mensal fixa de ~R\$ 46 mil mensais, 13o, verba de gabinete, imóveis funcionais e auxílio moradia, diárias em missões internacionais e a **cota parlamentar**
- CEAP - Cota Parlamentar:
 - Estabelecida em 2009, destina-se a custear gastos exclusivamente vinculados ao exercício da atividade parlamentar, observados os limites mensais estabelecidos de acordo com o estado de origem do parlamenta
 - Custeia despesas como **passagens, telefonia, escritórios, alimentação, hospedagem e divulgação de atividades, entre outros.**
 - Valores Mensais: Cada deputado tem direito entre **R\$ 36 mil a R\$ 51,4 mil mensais**, dependendo do estado de origem.
- A análise de dados pode revelar padrões e possíveis irregularidades nesses gastos públicos.
- A transparência dos dados de despesas públicas é fundamental para apoio no combate à corrupção e para ampliar o controle social através do acesso à informação.




Introdução

Objetivos

Objetivos:




- Explorar base de gastos do CEAP
- **Verificar se é possível agrupar deputados federais por padrão de gastos do CEAP, considerando as diferentes categorias.**
- Uso de métodos não supervisionados com natureza exploratória:
 - Clusterização por aglomeração hierárquica
 - Clusterização k-means.
- Avaliar categorias com maior potencial de uso abusivo.



Materiais e Métodos

Etapas gerais da Análise



Materiais

Obtenção da base de dados

- Fonte: Dados abertos da Câmara dos Deputados.
- Período: 1/2/2023 a 30/4/2025 (57ª legislatura)
- Mais de 604 mil registros
- 623 deputados diferentes utilizaram as cotas, incluindo titulares e suplentes
- Variáveis: nome, partido, UF, categoria de gasto, valor líquido, entre outras.

Dados Abertos

Se você precisa de dados selecionados, um pouco de cada lei, consulte e experimente aqui mesmo a nova API RESTful, sua aliada para acessar os dados, suas possibilidades de busca e as estruturas de dados retornadas.

Se você prefere fazer download de conjuntos completos (e grandes) de dados de uma só vez, para selecionar e processar no seu computador, visite a seção de [Arquivos](#) e escolha o formato mais apropriado para você.

Bom trabalho e divirta-se!



API RESTful

Arquivos

Despesas pela Cota para Exercício da Atividade Parlamentar

Destes sobre as despesas autorizadas pela Cota para Exercício da Atividade Parlamentar de cada deputado desde 2001.

Os arquivos são separados por ano de ocorrência da despesa. As versões em XML, JSON e CSV são comprimidas em formato ZIP. A URL de acesso de cada arquivo tem o formato: [http://www.camara.org.br/atividade-legislativa/despesas/legislacao/ano/ano.zip](#), em que:

- `{ano}` é o ano de registro das despesas
- `{formato}` pode ser "xml", "json" ou "csv"
- `{zip}` só deve ser usado se `{formato}` for "xml" ou "json"

Observação: Esses arquivos não seguem os mesmos padrões de nomenclatura, identificadores e organização dos demais arquivos desta página. Explicações sobre as colunas estão disponíveis na Central de Tópicos.

[Atualização diária](#)

Por ano:

Ano	XML+ZIP	JSON+ZIP	CSV+ZIP	XLSX (Excel)	ODS (OpenOffice)
2025	XML	JSON	CSV	XLSX	ODS
2024	XML	JSON	CSV	XLSX	ODS
2023	XML	JSON	CSV	XLSX	ODS
2022	XML	JSON	CSV	XLSX	ODS

Materiais

Entendimento dos dados

Variável	Tipo	Descrição
txNomeParlamentar	object	Nome adotado pelo Parlamentar ao tomar posse do seu mandato.
ideCadastro	float64	Número que identifica unicamente um deputado federal na CD.
nuLegislatura	int64	Legislatura: Período de quatro anos coincidente com o mandato parlamentar dos Deputados Federais. No contexto da cota CEAP, representa o ano base de início da legislatura.
sgPartido	object	O seu conteúdo representa a sigla de um partido. Tem personalidade jurídica de direito privado e goza de autonomia e liberdade no que diz respeito à criação, organização e funcionamento, observados os princípios e preceitos constitucionais.
sgUF	object	No contexto da cota CEAP, representa a unidade da federação pela qual o deputado foi eleito e é utilizada para definir o valor da cota a que o deputado tem.
numSubCota	int64	No contexto da Cota CEAP, o conteúdo deste dado representa o código do Tipo de Despesa referente à despesa realizada pelo deputado e comprovada por meio da emissão de um documento fiscal, a qual é debitada na cota do deputado.
txtDescricao	object	O seu conteúdo é a descrição do Tipo de Despesa relativo à despesa em questão.
numEspecificacaoSubCota	int64	No contexto da CEAP há despesas cujo Tipo de Despesa necessita ter uma especificação mais detalhada (por exemplo, "Combustível"). Esse dado representa o código desta especificação mais detalhada.
txtDescricaoEspecificacao	object	Representa a descrição especificação mais detalhada de um referido Tipo de Despesa.
datEmissao	object	O conteúdo deste dado é a data de emissão do documento fiscal ou a data do documento que tenha dado causa à despesa.
vlrDocumento	object	O seu conteúdo é o valor de face do documento fiscal ou o valor do documento que deu causa à despesa. Quando se tratar de bilhete aéreo, esse valor poderá ser negativo, significando que o referido bilhete é um bilhete de compensação, pois compensa um outro bilhete emitido e não utilizado pelo deputado (idem para o dado vlrLiquido abaixo).
vlrGlosa	object	O seu conteúdo representa o valor da glosa do documento fiscal que incidirá sobre o Valor do Documento, ou o valor da glosa do documento que deu causa à despesa.
vlrLiquido	object	O seu conteúdo representa o valor líquido do documento fiscal ou do documento que deu causa à despesa e será calculado pela diferença entre o Valor do Documento e o Valor da Glosa. É este valor que será debitado da cota do deputado. Caso o débito seja do Tipo Telefonica e o valor seja igual a zero, significa que a despesa foi franqueada.
numMes	int64	O seu conteúdo representa o Mês da competência financeira do documento fiscal ou do documento que deu causa à despesa. É utilizado, junto com o ano, para determinar em que período o débito gerará efeito financeiro sobre a cota.
numAno	int64	O seu conteúdo representa o Ano da competência financeira do documento fiscal ou do documento que deu causa à despesa. É utilizado, junto com o mês, para determinar em que período o débito gerará efeito financeiro sobre a cota.

Materiais

Entendimento dos dados

Categorias de despesas que podem ser pagas com a Cota Parlamentar

- 1 - passagens aéreas, incluindo o despacho de bagagens pessoais e os serviços de acesso à internet oferecidos por companhias aéreas ou aeroportos;
- 2 - telefones dos gabinetes, dos escritórios nos estados e dos imóveis funcionais, e as despesas com o celular funcional do deputado. As contas devem ser de comprovada responsabilidade do parlamentar;
- 3 - manutenção de escritórios de apoio à atividade parlamentar, como locação de imóveis, energia elétrica, água e esgoto, acesso à internet, entre outros;
- 4 - assinatura de publicações;
- 5 - alimentação do deputado;
- 6 - hospedagem, exceto no Distrito Federal;
- 7 - despesas com locomoção por:
 - locação ou fretamento de aeronaves;
 - locação ou fretamento de veículos automotores (limite inacumulável de R\$ 12.713,00 mensais), permitida contratação de seguro;
 - locação ou fretamento de embarcações;
 - serviços de táxi, pedágio e estacionamento (limite inacumulável de R\$ 2.700,00 mensais);
 - passagens terrestres, marítimas ou fluviais.
- 8 - combustíveis e lubrificantes (limite inacumulável de R\$ 9.392,00 mensais);
- 9 - serviços de segurança de empresas especializadas (limite inacumulável de R\$ 8.700,00 mensais);
- 10 - divulgação da atividade parlamentar (exceto nos 120 dias anteriores à data das eleições, se o deputado for candidato - [Ato da Mesa 40/2012](#));
- 11 - participação em cursos, congressos ou eventos, realizados por instituição especializada (limite mensal inacumulável de 25% do valor da menor cota – hoje R\$7.697,17);
- 12 - complementação de auxílio-moradia, de acordo com o [Ato da Mesa 104/88](#) (limite inacumulável de R\$ 4.148,80 mensais).
- 13 - aquisição de tokens e certificados digitais.

Materiais

Pré-processamento

Pré-processamento – fase 1

- Ajuste de formatos:
 - Números decimais com pontos
- Criação de variáveis auxiliares:
 - NumAnomes_compet: número em formato AAAAMM representando ano e mês da competência do gastos, para apoio na exploração da base
 - Envolvendo as categorias de gastos: macro_categoria, desc_Subcota_Espec
- Adição de informações categóricas na base:
 - "cat_reeleicao": se deputado foi reeleito ou não, em relação ao mandato anterior.
 - "cat_cargo_titusup": se deputado é Titular ou Suplente

Pré-processamento – fase 2

Transformações para uso da base com clusterização

- Agrupamentos para somar variáveis.
- Pivoteamento para transformar gastos por categorias em Colunas específicas
- Normalização com Z-score

Variáveis originais

macro_categoria	numSubCota	txtDescricao	numEspecificacaoSubCota	txtDescricaoEspecificacao	desc_Subcota_Espec
AQUISIÇÃO DE TOKENS E CERTIFICADOS DIGITAIS	145	AQUISIÇÃO DE TOKENS E CERTIFICADOS DIGITAIS	0	NaN	AQUISIÇÃO DE TOKENS E CERTIFICADOS DIGITAIS
ASSINATURA DE PUBLICAÇÕES	12	ASSINATURA DE PUBLICAÇÕES	0	NaN	ASSINATURA DE PUBLICAÇÕES
COMBUSTÍVEIS E LUBRIFICANTES	3	COMBUSTÍVEIS E LUBRIFICANTES	1	Veículos Automotores	COMBUSTÍVEIS E LUBRIFICANTES - Veículos Automotores
COMBUSTÍVEIS E LUBRIFICANTES	3	COMBUSTÍVEIS E LUBRIFICANTES	2	Embarcações	COMBUSTÍVEIS E LUBRIFICANTES - Embarcações
COMBUSTÍVEIS E LUBRIFICANTES	3	COMBUSTÍVEIS E LUBRIFICANTES	3	Aeronaves	COMBUSTÍVEIS E LUBRIFICANTES - Aeronaves
COMBUSTÍVEIS E LUBRIFICANTES	3	COMBUSTÍVEIS E LUBRIFICANTES	4	Sem especificações	COMBUSTÍVEIS E LUBRIFICANTES - Sem Especificações
CONSULTORIAS, PESQUISAS E TRABALHOS TÉCNICOS	4	CONSULTORIAS, PESQUISAS E TRABALHOS TÉCNICOS	0	NaN	CONSULTORIAS, PESQUISAS E TRABALHOS TÉCNICOS
DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR	5	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR	0	NaN	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR
FORNECIMENTO DE ALIMENTAÇÃO DO PARLAMENTAR	13	FORNECIMENTO DE ALIMENTAÇÃO DO PARLAMENTAR	0	NaN	FORNECIMENTO DE ALIMENTAÇÃO DO PARLAMENTAR
HOSPEDAGEM ,EXCETO DO PARLAMENTAR NO DISTRITO ...	14	HOSPEDAGEM ,EXCETO DO PARLAMENTAR NO DISTRITO ...	0	NaN	HOSPEDAGEM ,EXCETO DO PARLAMENTAR NO DISTRITO ...
LOCAÇÃO OU FRETAMENTO	119	LOCAÇÃO OU FRETAMENTO DE AERONAVES	0	NaN	LOCAÇÃO OU FRETAMENTO DE AERONAVES
LOCAÇÃO OU FRETAMENTO	120	LOCAÇÃO OU FRETAMENTO DE VEÍCULOS AUTOMOTORES	0	NaN	LOCAÇÃO OU FRETAMENTO DE VEÍCULOS AUTOMOTORES
LOCAÇÃO OU FRETAMENTO	121	LOCAÇÃO OU FRETAMENTO DE EMBARCAÇÕES	0	NaN	LOCAÇÃO OU FRETAMENTO DE EMBARCAÇÕES

Materiais


Pré-processamento

- Amostra da tabela pré-processada (Fase 1)

txNomeParlamentar	ideCadastro	sgUF	sgPartido	cat_reeleicao	cat_cargo_titusup	numAnoMes_compet	desc_Subcota_Espec	vlrLiquido
Marcelo Moraes	133810	RS	PL	Reeleito	Titular	202304	MANUTENÇÃO DE ESCRITÓRIO DE APOIO À ATIVIDADE ...	250.00
Cobalchini	98148	SC	MDB	Nao_reeleito	Titular	202407	COMBUSTÍVEIS E LUBRIFICANTES - Veículos Automo...	100.00
Orlando Silva	178987	SP	PCdoB	Nao_reeleito	Suplente	202404	HOSPEDAGEM ,EXCETO DO PARLAMENTAR NO DISTRITO ...	1350.08
Daniel Barbosa	220582	AL	PP	Reeleito	Titular	202305	COMBUSTÍVEIS E LUBRIFICANTES - Veículos Automo...	303.18
Eduardo Bolsonaro	92346	SP	PL	Reeleito	Titular	202303	PASSAGEM AÉREA - RPA	576.27
Franciane Bayer	220551	RS	REPUBLICANOS	Nao_reeleito	Titular	202408	TELEFONIA	1.64
Thiago de Joaldo	220560	SE	PP	Nao_reeleito	Titular	202403	LOCAÇÃO OU FRETAMENTO DE VEÍCULOS AUTOMOTORES	11300.00
Allan Garcês	226708	MA	PP	Nao_reeleito	Suplente	202311	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR	3000.00
Natália Bonavides	204453	RN	PT	Reeleito	Titular	202501	TELEFONIA	124.99
Adail Filho	220714	AM	REPUBLICANOS	Nao_reeleito	Titular	202405	TELEFONIA	3.78

Aglomerção Hierárquica


- Inicialização: Cada observação (ponto de dados) é tratada, inicialmente, como um cluster independente (N observações = N clusters).
- Fusão Progressiva: O algoritmo realiza sucessivas uniões dos 2 clusters mais similares ou mais próximos, com base na métrica de distância definida.
- Resultado Final: O processo continua até que todas as observações estejam contidas em um único cluster grande
- Dendrograma: É a principal representação gráfica. Permite visualizar a formação progressiva dos grupos e a distância em que as fusões ocorreram
 - **Decisão de número de clusters é determinado visualmente**, cortando o dendrograma em uma altura onde a distância entre os clusters é maximizada.



- Distâncias ou Métricas de similaridade mais comuns:
 - **Euclidiana**: A distância em linha reta (padrão).
 - **Manhattan**: A soma das diferenças absolutas das coordenadas ("distância do quarteirão" ou citiblock).
 - **Chebyshev**: A maior diferença absoluta entre as coordenadas.
- Métodos de encadeamento: indica qual distância utilizar quando já existem clusters formados durante os estágios aglomerativos
 - **Single linkage**
 - **Average linkage**
 - **Complete linkage**

K-means

- Objetivo: minimizar a soma dos quadrados das distâncias (SSD) , ou distâncias Euclidianas, entre cada ponto e o centroide de seu cluster
- Precisa de definição prévia do número de clusters
- Centroides são definidos aleatoriamente
- Método é adequado para um grande volume de dados



Para ajudar a definir o número de clusters:

- **Método do Cotovelo (*Elbow Method*)**
 - Métrica: Calcula a Soma dos Quadrados das Distâncias (SSD ou *Inertia*) para diferentes números de clusters
 - Decisão: O número ideal de clusters é o ponto onde o ganho marginal de redução da SSD começa a diminuir drasticamente, formando um "cotovelo" no gráfico.
- **Coeficiente de Silhueta (*Silhouette Score*)**
 - Métrica: Avalia a coesão (quão bem um ponto se encaixa em seu *cluster*) versus a separação (quão distinto ele é dos *clusters* vizinhos). O resultado varia entre -1 e +1.
 - Decisão: O número de clusters que produzir a maior pontuação média de Silhueta é geralmente o mais adequado.

Métodos

Ferramentas usadas

- Linguagem de programação: Python



- Ambiente IDE: Jupyter Notebook



- Bibliotecas usadas:

- Pandas, Numpy, Scipy, Matplotlib, Seaborn, Plotly, Prince, Statsmodel, Pingouin, e Scikit-learn.

- Código do trabalho publicado no github da autora:


- https://github.com/DBWALLER/MBA_DataScience-Analytics/tree/main/TCC%20-%20Gastos%20parlamentares

Resultados e Discussão

Análise exploratória preliminar

Gastos por Estado


- São Paulo, Minas Gerais e Rio de Janeiro lideram os gastos totais, refletindo o maior número de deputados eleitos por serem estados mais populosos.
 - Estados do Norte apresentam média ponderada* de gastos mais alta em relação aos demais.
- (*) Ponderada em relação ao número de meses que parlamentar atuou.



Resultados e Discussão

Análise exploratória preliminar

Gastos por Partido Político




Resultados e Discussão

Análise exploratória preliminar

Evolução temporal


- Gastos aumentam ao longo do ano, com pico em dezembro. A priori, o saldo mensal não utilizado acumula-se durante o exercício financeiro, mas não pode ser transferido para o ano seguinte.
- Janeiro apresenta quedas abruptas devido ao recesso parlamentar (23/dez a 1º/fev), mas julho mantém gastos elevados apesar do recesso.



Resultados e Discussão

Análise exploratória preliminar

Gastos por Categoria




Resultados e Discussão

Análise exploratória preliminar

Evolução temporal de Gastos por Macro categoria



- Divulgaç



Resultados e Discussão

Análise exploratória preliminar

Os deputados que mais gastam



Resultados e Discussão

Clusterização (Etapas 1 e 2)

- Preparação de dados para uso em Clusterização: Transformação necessária para obter linhas com indivíduos distintos e mais variáveis quantitativas

1) Agrupamento por deputado, por `vlr_liquido` e por categoria

txNomeParlamentar	sgUF	sgPartido	cat_reeleicao	cat_cargo_titusup	flag_lid	genero	desc_Subcota_Espec	vlrLiquido
AJ Albuquerque	CE	PP	Reeleito	Titular	0	H	COMBUSTÍVEIS E LUBRIFICANTES - Veículos Auto...	83607.29
AJ Albuquerque	CE	PP	Reeleito	Titular	0	H	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR	155300.00
AJ Albuquerque	CE	PP	Reeleito	Titular	0	H	HOSPEDAGEM ,EXCETO DO PARLAMENTAR NO DISTRITO ...	40046.00
AJ Albuquerque	CE	PP	Reeleito	Titular	0	H	LOCAÇÃO OU FRETAMENTO DE AERONAVES	30000.00
AJ Albuquerque	CE	PP	Reeleito	Titular	0	H	LOCAÇÃO OU FRETAMENTO DE VEÍCULOS AUTOMOTORES	258713.00

2) Pivoteamento com base nas categorias:

Resultado: 623 registros ,
21 variáveis quantitativas

3) Remoção das variáveis
categóricas

4) Normalização Z-score de cada
uma das variáveis

Obtenção de 21 variáveis numéricas


nome_var_categoria_espec	vl_alimentacao	vl_assinaturas	vl_comb_aeronaves	vl_comb_autom	vl_comb_embarc	vl_comb_semespec	vl_cursos_eventos	vl_divulg_ativ
0	0.00	0.0	0.00	83607.29	0.00	0.0	0.0	155300.00
1	423.56	0.0	0.00	115139.89	780.80	0.0	0.0	151942.00
2	0.00	0.0	0.00	97259.19	0.00	0.0	0.0	656928.70
3	0.00	0.0	0.00	63038.98	18681.09	0.0	0.0	942950.00
4	12068.16	0.0	0.00	110208.29	0.00	0.0	0.0	389633.34
...	...	...	...	...	...	...	...	...
607	4663.91	0.0	69061.23	72169.41	1832.66	0.0	0.0	563409.55
608	11577.68	0.0	0.00	137170.84	0.00	0.0	0.0	295154.00
609	0.00	0.0	11160.60	135198.50	2072.00	0.0	0.0	870619.70
610	0.00	0.0	0.00	0.00	0.00	0.0	0.0	159000.00
611	0.00	0.0	34906.77	185806.66	0.00	0.0	0.0	159500.00

desc_Subcota_Espec	nome_var_categoria_espec
COMBUSTÍVEIS E LUBRIFICANTES - Veículos Auto...	vl_comb_autom
DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR	vl_divulg_ativ
HOSPEDAGEM ,EXCETO DO PARLAMENTAR NO DISTRITO ...	vl_hospedagem
LOCAÇÃO OU FRETAMENTO DE AERONAVES	vl_locfret_aeronave
LOCAÇÃO OU FRETAMENTO DE VEÍCULOS AUTOMOTORES	vl_locfret_autom
MANUTENÇÃO DE ESCRITÓRIO DE APOIO À ATIVIDADE ...	vl_manut_escritorio
PASSAGEM AÉREA - REEMBOLSO	vl_pass_aerea_reembolso
PASSAGEM AÉREA - SIGEPA	vl_pass_aerea_sigepa
TELEFONIA	vl_telefonia
COMBUSTÍVEIS E LUBRIFICANTES - Embarcações	vl_comb_embarc
FORNECIMENTO DE ALIMENTAÇÃO DO PARLAMENTAR	vl_alimentacao
PASSAGENS TERRESTRES, MARÍTIMAS OU FLUVIAIS	vl_pass_ter_mar_flu
SERVIÇO DE TÁXI, PEDÁGIO E ESTACIONAMENTO	vl_taxi_ped_estac
AQUISIÇÃO DE TOKENS E CERTIFICADOS DIGITAIS	vl_tokens
PASSAGEM AÉREA - RPA	vl_pass_aerea_rpa
ASSINATURA DE PUBLICAÇÕES	vl_assinaturas
COMBUSTÍVEIS E LUBRIFICANTES - Sem Especificações	vl_comb_semespec
SERVIÇO DE SEGURANÇA PRESTADO POR EMPRESA ESPE...	vl_servseguranca
COMBUSTÍVEIS E LUBRIFICANTES - Aeronaves	vl_comb_aeronaves
PARTICIPAÇÃO EM CURSO, PALESTRA OU EVENTO SIMILAR	vl_cursos_eventos
LOCAÇÃO OU FRETAMENTO DE EMBARCAÇÕES	vl_locfret_embarc
SERVIÇOS POSTAIS	vl_serv_postais

Resultados e Discussão

Clusterização - Etapa 1

- **Etapa 1:** escolha de todas 21 variáveis quantitativas analisadas – totais de gastos por categoria no período de 1/2/23 a 30/4/25
- Teste de correlação e verificação de colinearidade: Não há alta correlação entre variáveis. Vamos seguir a análise com todas




Resultados e Discussão

Clusterização - Etapa 1

Clusterização com Aglomeração Hierárquica


- Aglomeração hierárquica com distância **Euclidiana** – Encadeamento Single linkage



Resultados e Discussão

Clusterização - Etapa 1


- Aglomeração hierárquica com distância **Euclidiana** – Encadeamento Average linkage



Resultados e Discussão

Clusterização - Etapa 1


- Aglomeração hierárquica com distância **Euclidiana** – Encadeamento Complete linkage



Resultados e Discussão

Clusterização - Etapa 1


- Aglomeração hierárquica com distância **Manhattan** – Encadeamento Complete linkage



Resultados e Discussão

Clusterização - Etapa 1

- Aglomeração hierárquica com distância **Chebyshev** – Encadeamento Complete linkage




- Difícil visualização e interpretabilidade dos dendrograma.
- Será usado outro método.

Resultados e Discussão


Clusterização - Etapa 1

Clusterização com K-means : necessário definir o número de clusters

- Método de Elbow



- Método da Silhueta



- Escolha de 18 clusters

Resultados e Discussão

Clusterização - Etapa 1


Clusterização com K-means com k=18 clusters

- Teste ANOVA: para nível de significância de 5%, com exceção da variável, "vl_locfret_embarc", demais variáveis apresentam p-valor $<0,05$, portanto são estatisticamente relevantes na formação de pelo menos 1 cluster

Variável	F	p-valor	Variável	F	p-valor
vl_comb_semespec	362.5	0.000	vl_telefonia	43.3	0.000
vl_tokens	273.9	0.000	vl_taxi_ped_estac	39.5	0.000
vl_comb_embarc	152.3	0.000	vl_pass_aerea_sigepa	37.0	0.000
vl_cursos_eventos	135.2	0.000	vl_pis aérea reembolso	34.4	0.000
vl_servseguranca	129.9	0.000	vl_locfret_autom	33.5	0.000
vl_pass_ter_mar_flu	116.5	0.000	vl_comb_autom	32.5	0.000
vl_assinaturas	106.6	0.000	vl_hospedagem	31.2	0.000
vl_locfret_aeronave	58.9	0.000	vl_manut_escritorio	21.1	0.000
vl_alimentacao	58.4	0.000	vl_comb_aeronaves	5.1	0.000
vl_divulg_ativ	52.1	0.000	vl_locfret_embarc	0.2	1.000
vl_pass_aerea_rpa	51.7	0.000			

Fonte: Dados da Pesquisa.


- Visto que espacialmente não é possível distinguir clusters nem explicá-los, foi proposta nova etapa de análise



Resultados e Discussão

Clusterização - Etapa 2

- **Etapa 2: Adotar apenas 6 colunas de gastos com as categorias mais relevantes** em termos de total de gastos: "vl_divulg_ativ", "vl_pass_aerea_sigepa", "vl_locfret_autom", "vl_manut_escritorio", "vl_comb_autom" e "vl_hospedagem":
- **Explorado apenas Clusterização com K-means**
 - **Necessário definir o número de clusters**
- Método de Elbow



- Definido seguir com **5 clusters**, baseado no método do cotovelo e na potencial interpretabilidade dos clusters

Resultados e Discussão

Clusterização - Etapa 2


Clusterização com K-means com k=5 clusters

- Teste ANOVA: para nível de significância de 5%, todas as 6 variáveis apresentam p-valor $< 0,05$, portanto são estatisticamente relevantes na formação de pelo menos 1 cluster

Variável	F	p-valor
vl_divulg_ativ	859.0	0.00
vl_manut_escritorio	149.4	0.00
vl_pass_aerea_sigepa	149.4	0.00
vl_locfret_autom	133.9	0.00
vl_comb_autom	63.3	0.00
vl_hospedagem	19.8	0.00

Fonte. Dados da pesquisa

- Variável mais influente (maior F) : vl_divulg_parlamentar
- Melhor distinção de clusters
 - Cluster 4 ● : deputados com maiores gastos em divulgação e passagens.
 - Cluster 3 ● : menores gastos, maioria suplentes (52%) e não reeleitos (~70%)



Resultados e Discussão

Clusterização - Etapa 3

- Etapa 3:** nova transformação da base, considerando a média mensal de gastos de 6 categorias de cada deputado federal, considerando o número de meses que se observa atividade na base de gastos.
- Adotar as mesmas 6 categorias da etapa 2: "vl_divulg_ativ" "vl_pass_aerea_sigepa" "vl_locret_autom" "vl_manut_escritorio" "vl_comb_autom" e "vl_hospedagem".
- Exemplos da transformação da base para Etapa 3

nome_var_categoria_espec	txNomeParlamentar	sgUF	sgPartido	cat_reeleicao	cat_cargo_titusup	flag_lid	vl_alimentacao	vl_assinaturas	vl_comb_aeronaves
0	AJ Albuquerque	CE	PP	Reeleito	Titular	0	0.00	0.0	0.00
1	Abílio Brunini	MT	PL	Nao_reeleito	Titular	0	423.56	0.0	0.00
2	Acácio Favacho	AP	MDB	Reeleito	Titular	0	0.00	0.0	0.00
3	Adail Filho	AM	REPUBLICANOS	Nao_reeleito	Titular	0	0.00	0.0	0.00
4	Adilson Barroso	SP	PL	Nao_reeleito	Suplente	0	12068.16	0.0	0.00
...	...	...	...	...	...	...	...	...	...
607	Zé Silva	MG	SOLIDARIEDADE	Reeleito	Titular	0	4663.91	0.0	69061.23
608	Zé Trovão	SC	PL	Nao_reeleito	Titular	0	11577.68	0.0	0.00
609	Zé Vitor	MG	PL	Reeleito	Titular	0	0.00	0.0	11160.60
610	Átila Lins	AM	PSD	Reeleito	Titular	0	0.00	0.0	0.00
611	Átila Lira	PI	PP	Nao_reeleito	Titular	0	0.00	0.0	34906.77



Base normalizada com Z-score e remoção das variáveis categóricas, pronta para uso na Etapa 3

	vl_divulg_ativ	vl_pass_aerea_sigepa	vl_locret_autom	vl_manut_escritorio	vl_comb_autom	vl_hospedagem
0	-0.621156	-0.359656	0.445107	-0.832739	-0.064401	0.519551
1	-0.570953	-0.158201	0.435404	0.919269	0.513219	0.225557
2	0.470594	0.555516	0.331057	-0.902444	0.088549	-0.329807
3	1.093093	-0.405840	0.086678	-0.959805	-0.294838	-0.329807
4	-0.111151	-0.365488	0.820224	-0.016912	0.233624	0.008774


Resultados e Discussão

Clusterização - Etapa 3

- Explorado apenas Clusterização com K-means

- Necessário definir o número de clusters

- Método de Elbow



- Definido seguir com **5 clusters**

Resultados e Discussão

Clusterização - Etapa 3


Clusterização com K-means com k=5 clusters

- Teste ANOVA: para nível de significância de 5%, todas as 6 variáveis apresentam p-valor <0,05, portanto são estatisticamente relevantes na formação de pelo menos 1 cluster

Variável	F	p-valor
vl_divulg_ativ	506.84	0.00
vl_pass_aerea_sigepa	415.23	0.00
vl_manut_escritorio	295,22	0.00
vl_locfret_autom	272.8	0.00
vl_comb_autom	272.3	0.00
vl_hospedagem	68.9	0.00

- Variável mais influente: vl_divulg_parlamentar
- Cluster 4: apenas 3 deputados com comportamento fora da curva.
 - Prováveis outliers, que influenciam clusterização com k-means.
 - Potencial indício de uso abusivo da CEAP.

Cluster	TxNomeParlamentar	sgUF	sgPartido	cat_reeleicao	cat_cargo_titusup
4	Robinson Faria	RN	PL	Nao_reeleito	Titular
4	Marcelo Queiroz	RJ	PP	Nao_reeleito	Titular
4	Osmar Terra	RS	MDB	Reeleito	Titular



Conclusões

- Foi possível clusterizar os deputados em grupos com técnicas de modelagem não supervisionada k-means, em condições específicas, com menos variáveis participando da análise.
 - Não foi identificada a priori uma justificativa para esses padrões.
- Clusterização prejudicada provavelmente pela base de análise ser pequena, de apenas 623 registros. (referentes apenas a essa legislatura)
- Divulgação parlamentar é a categoria mais crítica: ausência de limites mensais e sazonalidade observada sugerem potencial para práticas abusivas. TCU já solicitou revisão dessas regras em 2019.
- Importante: técnicas de clusterização não supervisionada possuem natureza exploratória e não preditiva, ou seja, os resultados obtidos nesta análise só valem para o conjunto de dados avaliado.
- A presente análise contribui para conscientização sobre uso de recursos públicos e fomentou ideias para futuras avaliações desses gastos.

Sugestões de Trabalhos futuros

- Análise de Correspondência Múltipla: avaliar relações e padrões entre as variáveis categóricas (partido político, estado, etc) incluindo o output Cluster" obtido na Análise de clusterização
- Aplicar K-means++ para otimizar a escolha dos centróides iniciais e possivelmente melhorar a qualidade dos agrupamentos de dados.
- Realizar análise com base mais volumosa. Poder-se-ia Incluir dados de legislaturas anteriores (necessidade correção monetária)
- Detecção de Anomalias nos gastos, usando métodos como Z-score e Isolation Forest para identificar comportamentos atípicos nos gastos.
- Aplicar a Lei de Newcomb-Benford para detectar fraudes
- Examinar CNPJs , principalmente dos gastos com divulgação parlamentar, para detectar irregularidades

**MBA
USP
ESALQ**

**Exploração do Padrão
de Gastos de
Deputados Federais
com Cota Parlamentar
por Clusterização**