

Exploração do Padrão de Gastos de Deputados Federais com Cota Parlamentar por Clusterização

Dalciana Bressan Waller^{1*}, Eder Costa Cassettari²

¹ Mestre em Engenharia Química pela UFRGS. Especialista em Gestão empresarial pela FGV. R. Eusébio Matoso 1385 - Bairro Pinheiros, 05423-905 São Paulo, SP, Brasil.

² Doutorando em Engenharia Mecânica. Professor de Engenharia de Produção, Mecânica e Data Science. Docente na USP nos MBAs de Data Science e Gestão de Produção e Operações

*autor correspondente: dalciana.waller@gmail.com

Exploração do Padrão de Gastos de Deputados Federais com Cota Parlamentar por Clusterização

Resumo

Este trabalho investigou os padrões de gastos dos deputados federais brasileiros com a Cota para o Exercício da Atividade Parlamentar (CEAP), com foco na identificação de agrupamentos por meio de técnicas de clusterização não supervisionadas. Utilizou-se uma base pública da Câmara dos Deputados, referente à 57ª legislatura (2023–2025), contendo mais de 600 mil registros. Após tratamento e organização dos dados, foram aplicadas técnicas de aglomeração hierárquica e K-means em três etapas distintas, considerando valores totais, valores médios mensais e variáveis com maior representatividade financeira. Os resultados indicaram que, de forma geral, os padrões de gastos entre parlamentares são bastante semelhantes, dificultando a distinção clara entre grupos. No entanto, ao considerar apenas as variáveis mais relevantes, como divulgação da atividade parlamentar, passagens aéreas e locação de veículos, foi possível formar agrupamentos mais definidos. A categoria de divulgação parlamentar destacou-se como a mais significativa e potencialmente vulnerável a práticas abusivas, devido à ausência de limites mensais e à sazonalidade observada nos gastos. A análise também identificou um pequeno grupo de parlamentares com comportamento de gastos significativamente acima da média, sugerindo a necessidade de investigações adicionais. Concluiu-se que, embora os padrões gerais sejam homogêneos, a análise segmentada permite identificar perfis específicos de consumo que podem subsidiar ações de controle e transparência.

Palavras-chave: despesas públicas, CEAP, transparência, clusterização

Introdução

Segundo Silva et. al. (2024), a transparência e a abertura de dados figuram como aspectos primordiais de um governo moderno, destacando como benefícios a participação democrática e compreensão do cidadão, a melhoria do processo de tomada de decisão, do gerenciamento dos dados governamentais, da eficiência da gestão e dos serviços oferecidos aos cidadãos. Segundo relatório do TCU (2018), parece haver um consenso de que a principal função da transparência está no combate à corrupção. A transparência na administração pública tende a inibir práticas de corrupção, pois o controle social cresce ao se ampliar o acesso à informação.

Conforme apresenta Lemos e Joseph (2010), o parlamento brasileiro disponibiliza inúmeras maneiras de utilização do dinheiro público para a execução e manutenção da atividade de deputados e senadores, e que, nos últimos anos, foram mais bem reguladas para conferir maior divulgação e acompanhamento da atividade parlamentar.

E para desenvolvimento dessas atividades, segundo o site da Câmara¹, os deputados federais têm direito a diversos tipos de auxílio financeiro: remuneração mensal (tributável), verba de gabinete para pagar secretários parlamentares, auxílio-moradia (caso

¹ <https://www.camara.leg.br/transparencia/gastos-parlamentares/>

não fazer uso dos imóveis funcionais), verbas especiais para caso de viagens internacionais e a Cota para o Exercício da Atividade Parlamentar (CEAP), objeto de análise deste trabalho.

Como meio de transparência na utilização de recursos públicos, a Câmara divulga suas despesas da cota parlamentar desde 2014, após emissão da Portaria 228/2014², que determina a disponibilização de cópias digitalizadas de notas fiscais correspondentes.

A CEAP foi estabelecida em 2009, segundo informações da Câmara sobre as cotas³, e custeia as despesas do mandato como: passagens aéreas, telefonia, manutenção de escritórios de apoio à atividade parlamentar, assinatura de publicações; fornecimento de alimentação do(a) parlamentar, hospedagem, exceto do(a) parlamentar no Distrito Federal, despesas de locomoção (locação ou fretamento de automóveis, aeronave etc), combustíveis, serviços de segurança, participação em cursos e palestras e divulgação da atividade parlamentar(exceto nos 120 dias anteriores à data das eleições de âmbito federal, estadual ou municipal, salvo se o deputado não for candidato à eleição) e hospedagem (fora de Brasília).

Nos casos de reembolso, os deputados têm até 3 meses para apresentar os recibos. Para algumas categorias, o valor mensal não utilizado fica acumulado ao longo do ano, logo em alguns meses o valor gasto pode ser maior que a média mensal. Cada deputado tem direito a um valor mensal entre 36 mil a 51,4 mil reais de cota, dependendo do estado de origem, conforme site da assessoria de imprensa da Câmara⁴.

Considerando o contexto acima, o presente trabalho busca ser um instrumento para exploração dessa base de gastos do CEAP e avaliação sobre a existência ou não de padrões de despesas de diferentes categorias. Foram usadas técnicas para verificar a existência de comportamentos semelhantes, como modelos de “machine-learning” não supervisionadas de clusterização por aglomeração hierárquica e k-means. Um benefício adicional deste estudo é contribuir para a conscientização da população pagadora de impostos de como parte desses recursos públicos são consumidos pelos deputados federais e verificar se as regras hoje aplicadas para os gastos facilitam a ocorrência de abusos.

Material e Métodos

Materiais

²

<https://www2.camara.leg.br/login/int/portar/2014/portaria-228-18-junho-2014-779144-publicacaooriginal-144692-cd-dg.html>

³

<https://www2.camara.leg.br/a-camara/documentos-e-pesquisa/arquivo/sites-tematicos/57a-legislatura/no-exercicio-o-do-mandato/cota-para-o-exercicio-da-atividade-parlamentar-ceap>

⁴ <https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/cota-parlamentar>

Este trabalho utilizou as bases públicas de dados de gastos registrados de cota parlamentar, disponíveis no Portal da Câmara dos deputados através do site de dados abertos⁵. As bases estão disponíveis por ano de competência (quando o gasto efetivamente ocorre) e os gastos são registrados individualmente. Foram utilizados arquivos em formato csv dos anos de 2023, 2024 e 2025, anos da legislatura vigente (57^a). As informações das colunas disponíveis e trabalhadas na análise estão na Tabela 1, baseadas no dicionário de dados da base do CEAP⁶.

Tabela 1. Descrição das variáveis presentes na base de dados de gastos de cotas parlamentares e utilizadas na análise, em alguma etapa.

Métrica	Tipo	Descrição
txNomeParlamentar	object	Nome adotado pelo Parlamentar ao tomar posse do seu mandato.
ideCadastro	float64	Número que identifica unicamente um deputado federal na CD.
nuLegislatura	int64	Legislatura: Período de quatro anos coincidente com o mandato parlamentar dos Deputados Federais. No contexto da cota CEAP, representa o ano base de início da legislatura.
sgPartido	object	O seu conteúdo representa a sigla de um partido. Tem personalidade jurídica de direito privado e goza de autonomia e liberdade no que diz respeito à criação, organização e funcionamento, observados os princípios e preceitos constitucionais.
sgUF	object	No contexto da cota CEAP, representa a unidade da federação pela qual o deputado foi eleito e é utilizada para definir o valor da cota a que o deputado tem.
numSubCota	int64	No contexto da Cota CEAP, o conteúdo deste dado representa o código do Tipo de Despesa referente à despesa realizada pelo deputado e comprovada por meio da emissão de um documento fiscal, a qual é debitada na cota do deputado.
txtDescricao	object	O seu conteúdo é a descrição do Tipo de Despesa relativo à despesa em questão.
numEspecificacaoSubCota	int64	No contexto da CEAP há despesas cujo Tipo de Despesa necessita ter uma especificação mais detalhada (por exemplo, "Combustível"). Esse dado representa o código desta especificação mais detalhada.

⁵ <https://dadosabertos.camara.leg.br/swagger/api.html?tab=staticfile>

⁶ <https://dadosabertos.camara.leg.br/howtouse/2023-12-26-dados-ceap.html>

Métrica	Tipo	Descrição
txtDescricaoEspecificacao	object	Representa a descrição especificação mais detalhada de um referido Tipo de Despesa.
datEmissao	object	O conteúdo deste dado é a data de emissão do documento fiscal ou a data do documento que tenha dado causa à despesa.
vlrDocumento	object	O seu conteúdo é o valor de face do documento fiscal ou o valor do documento que deu causa à despesa. Quando se tratar de bilhete aéreo, esse valor poderá ser negativo, significando que o referido bilhete é um bilhete de compensação, pois compensa um outro bilhete emitido e não utilizado pelo deputado (idem para o dado vlrliquido abaixo).
vlrGlosa	object	O seu conteúdo representa o valor da glosa do documento fiscal que incidirá sobre o Valor do Documento, ou o valor da glosa do documento que deu causa à despesa.
vlrLiquido	object	O seu conteúdo representa o valor líquido do documento fiscal ou do documento que deu causa à despesa e será calculado pela diferença entre o Valor do Documento e o Valor da Glosa. É este valor que será debitado da cota do deputado. Caso o débito seja do Tipo Telefonia e o valor seja igual a zero, significa que a despesa foi franqueada.
numMes	int64	O seu conteúdo representa o Mês da competência financeira do documento fiscal ou do documento que deu causa à despesa. É utilizado, junto com o ano, para determinar em que período o débito gerará efeito financeiro sobre a cota.
numAno	int64	O seu conteúdo representa o Ano da competência financeira do documento fiscal ou do documento que deu causa à despesa. É utilizado, junto com o mês, para determinar em que período o débito gerará efeito financeiro sobre a cota.
vlrRestituicao	object	O seu conteúdo representa o valor restituído do documento fiscal que incidirá sobre o Valor do Documento.

O banco de dados passou por um tratamento e ajuste para melhor aproveitamento das informações, como mudanças dos campos envolvendo montantes financeiros, bem como criação de variáveis auxiliares para as análises.

Foi necessário juntar as bases dos anos de 2023, 2024 e 2025, e filtro para a Legislatura (campo “nuLegislatura”) de 2023. Foram utilizados os dados de competência entre 1/2/2023, início do mandato vigente, até o dia 30/4/2025. Essa data de corte foi escolhida, pois, segundo o site de assessoria de imprensa⁷, parlamentares têm até 90 dias

⁷ <https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/cota-parlamentar>

corridos país o gasto para comprovar uma despesa. No período de realização do trabalho, pôde-se considerar como completa a base até abril/2025. A base contém 604.374 registros.

Após estudo das variáveis associadas às categorias, e para fins de facilitação nas análises, foram criadas as variáveis auxiliares:

(a) “macro_categorias”: para agrupar a “txtDescricao”, sendo os itens os seguintes: manutenção de escritório de apoio à atividade parlamentar, combustíveis e lubrificantes, fornecimento de alimentação do parlamentar, locação ou fretamento, divulgação da atividade parlamentar, passagem aérea, hospedagem ,exceto do parlamentar no distrito federal, serviço de táxi, pedágio e estacionamento, assinatura de publicações, serviço de segurança prestado por empresa especializada, telefonia, passagens terrestres, marítimas ou fluviais, serviços postais, aquisição de tokens e certificados digitais, participação em curso, palestra ou evento similar.

(b) “desc_Subcota_Espec”: junta a “txtDescricao” com a “txtDescricaoEspecificacao”, importante para o caso de designação de combustíveis (para automóveis, aeronaves etc).

Outras variáveis categóricas adicionais associadas aos deputados foram inseridas:

(c) “cat_reeleicao” foi inserida, para marcar quais deputados estavam na 56a legislatura e foram reeleitos para a legislatura vigente, com valores “Reeleito” ou “Nao_reeleito”. A relação dos deputados reeleitos foi disponibilizada através do site de reeleitos da Câmara⁸ e organizada em planilha Excel.

(d) “cat_cargo_titusup” para marcar se o parlamentar em questão era “Titular”, ou seja, entrou em uma das 513 vagas previstas diretamente ou “Suplente”, se substituiu algum parlamentar temporariamente ou permanentemente. A relação de titulares foi obtida através do site de eleitos da Câmara⁹. Segundo o site sobre perguntas frequentes da Câmara¹⁰, um suplente assume o mandato de deputado se o titular se afastar definitivamente (por morte, renúncia ou cassação) ou em afastamentos temporários (licenças superiores a 120 dias).

A variável métrica de interesse “vlrLiquido”, foi tratada para formato decimal com ponto. Para fins de simplificação, foi decidido não utilizar a atualização monetária.

Para facilitar também as buscas de dados por mês e ano, foi gerada a coluna “numAnoMes_compet”, em formato AAAAMM (ano e mês), marcando o período em que o fato gerador do gasto ocorreu. Essa coluna se difere da “datEmissao”, pois essa mostra quando a nota fiscal foi emitida, podendo ter ocorrido em outro mês, o que não é relevante nas análises.

⁸

<https://www.camara.leg.br/noticias/912220-reeleicao-na-camara-alcanca-57-veja-quais-deputados-foram-reeleitos/>

⁹<https://www.camara.leg.br/internet/agencia/infograficos-html5/tabelasEleicoes/deputados-eleitos-estado/index.html>

¹⁰https://www2.camara.leg.br/transparencia/acesso-a-informacao/copy_of_perguntas-frequentes/deputados##13

As variáveis utilizadas nas análises foram: “txNomeParlamentar”, “nuLegislatura”, “sgUF”, “sgPartido”, “cat_cargo_titusup”, “cat_reeleicao”, “macro_categoria”, “desc_Subcota_Espec”, “vlrLiquido”, “numAnoMes_compet”. As variáveis “cpf”, “ideCadastro”, “vlrDocumento” e “vlrGlosa” foram usadas apenas em algumas verificações.

Todos as etapas de transformação da base e as análises apresentadas nesse trabalho estão disponíveis em repositório do github da autora¹¹.

Métodos

Segundo Fávero e Belfiore (2017), técnicas de clusterização não supervisionadas são usadas para agrupar dados semelhantes sem a necessidade de rótulos pré-definidos, utilizando variáveis métricas ou quantitativas. Elas são fundamentais em tarefas de análise exploratória, segmentação de mercado, reconhecimento de padrões, entre outras. No presente trabalho as técnicas de aglomeração hierárquica e k-means foram empregadas.

A aglomeração hierárquica é uma técnica que organiza os dados em uma estrutura de árvore, chamada dendrograma, revelando como os grupos se formam progressivamente. Na abordagem aglomerativa (“bottom-up”), começa com cada observação como um grupo separado e vai unindo os grupos mais próximos.

A similaridade entre observações é medida por uma função de distância. As mais comuns podem ser obtidas a partir da distância de Minkowski, medida de dissimilaridade mais geral:

$$d_{pq} = \left[\sum_{j=1}^k (ZX_{jp} - ZX_{jq})^m \right]^{1/m} \quad (1)$$

O prefixo Z, na expressão acima, quer dizer que variável é padronizada. Os subcasos dessa medida incluem:

- Distância Manhattan (m=1): mede a distância absoluta ou bloco.

$$d_{pq} = \sum_{j=1}^k |ZX_{jp} - ZX_{jq}| \quad (2)$$

- Distância Euclidiana (m=2): mede a distância linear entre dois pontos no espaço.

$$d_{pq} = \sqrt{\sum_{j=1}^k (ZX_{jp} - ZX_{jq})^2} \quad (3)$$

¹¹https://github.com/DBWALLER/MBA_DataScience-Analytics/tree/main/TCC%20-%20Gastos%20parlamentares

- Distância de Chebyshev ($m \rightarrow \infty$): considera apenas a maior diferença entre dimensões.

$$d_{pq} = \max | (ZX_{jp} - ZX_{jq}) | \quad (4)$$

Após calcular as distâncias entre os pontos, é necessário definir como medir a distância entre grupos, através de alguns critérios como:

- Encadeamento Simples ("Single linkage"): usa a menor distância entre elementos de dois grupos.
- Encadeamento Completo ("Complete linkage"): considera a maior distância entre elementos dos grupos.
- Encadeamento Médio ("Average linkage"): calcula a média das distâncias entre todos os pares de elementos dos grupos.

Cada método de encadeamento gera dendrogramas com estruturas distintas, influenciando a interpretação dos agrupamentos.

Outro método utilizado no presente trabalho é o não hierárquico K-means. O critério de agrupamento é baseado na minimização da soma das distâncias quadráticas entre os pontos e seus respectivos centróides. Segundo Fávero e Belfiore (2017), o método K-means é uma técnica de agrupamento baseada em partição, cujo objetivo é dividir um conjunto de dados em K grupos distintos, de forma que os elementos dentro de cada grupo sejam o mais semelhantes possível entre si, e o mais diferentes possível dos elementos de outros grupos. A semelhança é geralmente medida por uma função de distância, sendo a distância euclidiana a mais comum. Nesta técnica, a formação dos conjuntos é feita com a determinação aleatória de um centroide.

O critério de agrupamento é a minimização da soma das distâncias quadráticas entre os pontos e seus respectivos centróides. A função objetivo é dada por:

$$SS = \sum_{k=1}^k \sum_{x_j \in C_i}^k (x_i - \mu_k)^2 \quad (5)$$

Onde μ_k é o centroide do grupo "k" e o termo interno representa a distância quadrática entre o ponto x_j e o centroide.

O K-means é eficiente para grandes volumes de dados, mas exige a definição prévia de clusters. Para obter esse número, são usados métodos como o do cotovelo (“elbow method”), que avalia a soma dos quadrados intra-grupo, e o da silhueta.

Para desenvolvimento das análises foi utilizada a linguagem Python utilizando o Jupyter Notebook como ambiente de desenvolvimento integrado (IDE) que combina a edição e execução de código com a visualização de resultados. Dentre os pacotes utilizados estão o Pandas, Numpy, Scipy, Matplotlib, Seaborn, Plotly, Prince, Statsmodel, Pinguin, e Scikit-learn, este último necessário para rodar os algoritmos de clusterização.

Para apoio em verificações, por exemplo, se políticos foram ou não reeleitos, e atribuição de titular ou suplente e qual o gênero do parlamentar, foi utilizado Microsoft Excel online.

Resultados e Discussão

Análise exploratória preliminar

A primeira etapa de exploração é a verificação de inconsistências quanto a legislaturas e cadastros. Primeiramente explorou-se se deputados da legislatura anterior, a 56^a, que iniciou em 31/1/2019 e findou-se em 31/01/2023 tiveram gastos em datas de competência indevida. Verificou-se que efetivamente só ocorreram gastos das cotas em janeiro de 2023, último mês de mandato, o que era esperado. Sem anomalias nesse quesito.

Também foram analisadas as quantidades de deputados que apareceram na base de gastos a partir de fevereiro de 2023: 623 nomes diferentes de deputados usaram as cotas. No entanto foram formalmente eleitos na 57^a legislatura 513 deputados¹², dos quais 294¹³ foram reeleitos. Essa divergência de quantidades ocorre, pois deputados suplentes podem assumir o cargo durante o mandato. Segundo o site de acesso à informação da câmara¹⁴, o suplente é convocado quando um deputado precisa se afastar do exercício do seu mandato, em casos de vacância, de licença superior a 120 dias ou quando o titular é investido nos cargos de Ministro de Estado, entre outros. Outro ponto levantado na exploração da base é que temos no campo do nome do deputado, 15 siglas de liderança dos partidos ou da câmara: Lid-Gov-CD, Liderança do MDB, Liderança do Novo, Liderança do PT entre outros. Para a análise em questão, esses dados não foram considerados. Também foi detectado que há registros de 27 deputados que não tiveram CPF mencionado no gasto, sendo uma falha no cadastro da despesa.

¹² <https://www.camara.leg.br/internet/agencia/infograficos-html5/tabelasEleicoes/deputados-eleitos-estado/>

¹³

<https://www.camara.leg.br/noticias/912220-reeleicao-na-camara-alcanca-57-veja-que-deputados-foram-reeleitos/>

¹⁴ https://www2.camara.leg.br/transparencia/acesso-a-informacao/copy_of_perguntas-frequentes/deputados

A próxima etapa é observar padrões de gastos por unidade federativa que o parlamentar representa. De acordo com a Figura 1, os deputados de São Paulo, Minas Gerais e Rio de Janeiro totalizaram a maior quantidade de gastos com cota parlamentar desde o início do mandato. Isso faz sentido, por serem os estados com maior número de deputados eleitos, conforme também apresentado na Figura 1, e isso decorre de serem estados mais populosos. Essa regra é descrita no site de assessoria de imprensa da câmara¹⁵.



Figura 1. Gastos totais dos deputados por Unidade Federativa, do início da legislatura, 1/2/2023 até 30/4/2025, e número de deputados por estado. Fonte: Resultados originais da pesquisa

Valores absolutos são mais complexos de serem avaliados e interpretados. Portanto, foram levantados os gastos médios por deputados, ponderados pelo número de meses que o parlamentar atuou até a data de corte dos dados.




Figura 2. Gastos médios por deputados (ponderados pelo número de meses de serviço) representando a Unidade Federativa, do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa.

Deputados de estados do Norte do país apresentam média ponderada de gastos com CEAP mais alta em relação aos demais.

A Figura 3 apresenta o uso da cota por partido político e na Figura 4 aparece o valor médio por deputado por partido. Pode-se aproveitar a oportunidade de ver se partidos que alegam gastar menos recursos públicos, como o partido NOVO, estão efetivamente fazendo jus a esse mote. E isso se confirma: são um dos que apresenta menor valor de gasto médio por deputado.

¹⁵ <https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/camara-dos-deputados>




Figura 3. Gastos totais dos deputados por Partido Político, do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa




Figura 4: Gastos médios por deputado (ponderados pelo número de meses de serviço) representando o Partido, do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa

Foi efetuado também uma exploração temporal dos gastos. Conforme apresentado na Figura 5, nota-se que no início do mandato são poucos os gastos, mas à medida que os meses avançam, os gastos sobem, principalmente em dezembro. Segundo o site de assessoria de imprensa sobre cotas parlamentares¹⁶, o saldo mensal não utilizado em um mês acumula-se ao longo do exercício financeiro, vedada a acumulação de um exercício financeiro para o seguinte. No entanto, existem regras de limites mensais impostas. A conclusão a priori é que existe uma tendência a usar o saldo, contudo precisamos avaliar se se trata de gastos pertinentes ou usam alguma estratégia para “queimar” esse montante do dinheiro público.

Segundo o site de assessoria de imprensa da câmara dos deputados¹⁷, o recesso parlamentar ocorre todo ano, entre 18 e 31 de julho e entre 23 de dezembro e 1º de fevereiro. Em janeiro de 2024 e janeiro de 2025, notou-se uma queda abrupta de gastos, condizente com o período de recesso parlamentar, mas nos meses de julho, quando também há um recesso de menor duração, não reduz significativamente.

¹⁶ <https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/cota-parlamentar>

¹⁷ <https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/recesso-dos-deputados>




Figura 5. Evolução temporal do total de gastos, em termos de mês e ano, com cotas parlamentares desde o início da 57ª legislatura. Fonte: Resultados originais da pesquisa

A próxima etapa foi analisar a distribuição de gastos por categoria. Categoriza-se os dados das cotas parlamentares da seguinte maneira: divulgação da atividade parlamentar, aluguel de veículos (locação ou fretamento), passagens aéreas, manutenção de escritório, combustíveis entre outras. Gastos com divulgação de atividades parlamentares é de longe a categoria mais significativa de uso das cotas, totalizando quase 40% dos gastos, conforme apresentado na Figura 6.

Dada essa indicação de discrepância por categoria, decidiu-se abrir uma análise temporal por macro categoria. Segundo site de assessoria de imprensa sobre as cotas¹⁸ algumas das categorias possuem um limite máximo total mensal não acumulável de um mês para outro, tal como combustíveis e lubrificantes (limite inacumulável de R\$ 9.392,00 mensais); locação ou fretamento de veículos automotores (limite inacumulável de R\$ 12.713,00 mensais), serviços de táxi, pedágio e estacionamento (limite inacumulável de R\$ 2.700,00 mensais); combustíveis e lubrificantes (limite inacumulável de R\$ 9.392,00 mensais); serviços de segurança de empresas especializadas (limite inacumulável de R\$ 8.700,00 mensais). participação em cursos, congressos ou eventos, realizados por instituição especializada (limite mensal inacumulável de 25% do valor da menor cota – hoje R\$7.697,17). Essas restrições justificam o comportamento dessas categorias que se mantêm relativamente constantes.

¹⁸ <https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/cota-parlamentars>




Figura 6. Gastos totais dos deputados por Macro categoria, do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa

Conforme mostra a Figura 7, a categoria de Divulgação e atividade parlamentar não possui limite de gastos mensais. Apresenta ainda uma sazonalidade, sendo que aumenta os gastos do meio do ano em diante. Uma hipótese é que, sabendo que a cota não utilizada é perdida de um ano para outro, esses deputados poderiam estar se aproveitando dessa regra valor contratando serviços de necessidade duvidosa (ou ainda, destinos duvidosos ou até esquemas ilícitos com os fornecedores) aproveitando-se da falta de limite mensal. Ou seja, é a mentalidade: “se tem, por que não usar?”. Nessa categoria de gastos são apontados gastos de produção de conteúdo e manutenção de redes sociais, impressão de jornais e panfletos, além de propaganda ou patrocínio a sites e blogs alinhados nos estados.

Esse problema não é novo. Segundo um relatório de monitoramento do uso do CEAP, no Acórdão 3048/2019, feito pelo TCU (2019), tribunal responsável pela fiscalização financeira do legislativo, já houve solicitação de revisão nas regras desta rubrica. O TCU solicitou aos parlamentares que revejam os gastos reembolsados a título de “divulgação da atividade parlamentar”. O TCU considera que esses serviços já são atualmente supridos pelos meios de divulgação oficiais das casas legislativas ou pelas redes sociais, gratuitas. O tribunal salientou ainda que parlamentares deveriam fixar critérios e valores máximos para esse dispêndio, por exemplo, para áreas remotas que não possuam acessos à internet ou a sinais de TV ou rádio.




Figura 7. Gastos totais dos deputados por Macro categoria por mês, do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa

Como etapa final da exploração preliminar, foram avaliados gastos a nível de indivíduo, mostrando quais os deputados que mais usaram as cotas a nível de soma total e a nível médio por mês (considerando o número de meses de exercício), nas Figuras 8 e 9 respectivamente.




Figura 8. Deputados que mais utilizaram a cota parlamentar, do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa

A Figura 10 mostra os 20 deputados com menor montante de despesas. Varia de alguns milhares de reais até valores negativos. Segundo o dicionário de dados da base de gastos de cota¹⁹, alguns tipos de despesa podem ter registros com valores negativos: nos de passagens aéreas, por exemplo, isso ocorre quando são emitidos bilhetes de compensação pela não-utilização de uma passagem.

¹⁹ <https://dadosabertos.camara.leg.br/howtouse/2023-12-26-dados-ceap.html>




Figura 9. Valor médio mensal dos deputados que mais utilizaram a cota parlamentar do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa

Os deputados com menores gastos ficaram no cargo entre 1 e 4 meses no período avaliado, ou seja, foram quase todos Suplentes ou eram Titulares que ficaram pouco tempo no cargo.




Figura 10. Deputados que mais utilizaram a cota parlamentar do início da legislatura, 1/2/2023 até 30/4/2025. Fonte: Resultados originais da pesquisa

Exploração com métodos não supervisionados de clusterização

O objetivo dessa etapa foi verificar se existe como distinguir grupos de parlamentares por padrões gerados a partir dos gastos com cota em diferentes categorias.

Para termos 1 registro por parlamentar, foi necessário realizar somas agrupadas dos valores de gastos. Na primeira parte da exploração com métodos não supervisionados (designada “Etapa 1”), foi considerada a soma total em todo o período da base, de 1/2/2023 até 30/4/2025. Foi necessário fazer uma transformação da base, os valores de gastos por deputado foram agrupados pela categoria detalhada do gasto, através da variável criada “desc_Subcota_Espec”.

Métodos de clusterização necessitam de pelo menos 2 variáveis métricas. Visto que a base possuía 1 coluna métrica de interesse, “vlrLiquido”, mas que as categorias de gastos

estavam designadas em linhas, foi realizado pivoteamento de variáveis, transformando em colunas os valores de gastos para categoria, gerando as variáveis, tal como apresentado na amostra do print do “dataframe” gerado, na Figura 11.

Após essa etapa, foi efetuada a normalização das variáveis, através do método Z-score. Mesmo que suas variáveis sejam todas monetárias e relacionadas a despesas elas representam fenômenos de consumo diferentes com escalas diferentes, portanto optou-se por padronizar.

Para uso da base, as variáveis qualitativas foram eliminadas da base e mantidas apenas as seguintes: 'vl_alimentacao', 'vl_assinaturas', 'vl_comb_aeronaves', 'vl_comb_autom', 'vl_comb_embarc', 'vl_comb_semespec', 'vl_divulg_ativ', 'vl_hospedagem', 'vl_cursos_eventos', 'vl_locfret_aeronave', 'vl_locfret_autom', 'vl_locfret_embarc', 'vl_manut_escritorio', 'vl_telefonia', 'vl_tokens', 'vl_pass_aerea_rpa', 'vl_pass_aerea_sigepa', 'vl_pass_aerea_reembolso', 'vl_pass_ter_mar_flu', 'vl_servseguranca', 'vl_taxi_ped_estac'.

A variável vl_servicos_postais foi eliminada por ter valores irrisórios..

nome_var_categoria_espec	vl_alimentacao	vl_assinaturas	vl_comb_aeronaves	vl_comb_autom	vl_comb_embarc	vl_comb_semespec	vl_cursos_eventos	vl_divulg_ativ
0	0.00	0.0	0.00	83607.29	0.00	0.0	0.0	155300.00
1	423.56	0.0	0.00	115139.89	780.80	0.0	0.0	151942.00
2	0.00	0.0	0.00	97259.19	0.00	0.0	0.0	656928.70
3	0.00	0.0	0.00	63038.98	18681.09	0.0	0.0	942950.00
4	12068.16	0.0	0.00	110208.29	0.00	0.0	0.0	389633.34
...	...	...	...	...	...	...	...	...
607	4663.91	0.0	69061.23	72169.41	1832.66	0.0	0.0	563409.55
608	11577.68	0.0	0.00	137170.84	0.00	0.0	0.0	295154.00
609	0.00	0.0	11160.60	135198.50	2072.00	0.0	0.0	870619.70
610	0.00	0.0	0.00	0.00	0.00	0.0	0.0	159000.00
611	0.00	0.0	34906.77	185806.66	0.00	0.0	0.0	159500.00

Figura 11. Impressão de tela de amostra do “dataframe” agrupado para análise não supervisionada, ainda não normalizado. Fonte. Dados da pesquisa

Uma análise de correlação de Pearson foi efetuada para verificar se havia risco de colinearidade entre algumas das variáveis envolvidas. Conforme mostrado na Figura 12, as correlações são baixas entre as variáveis, então não foi necessário remover nenhuma variável por efeitos de colinearidade.




Figura 12. Matriz de correlação das variáveis pivotadas na Etapa 1. Fonte: Dados originais da pesquisa

Uma vez a base preparada, foi aplicada a técnica de aglomeração hierárquico com distância Euclidiana com diferentes tipos de encadeamento, “single”, “average” e “complete linkage”, nas Figuras 13, 14 e 15 respectivamente.




Figura 13. Dendrograma para aglomeração hierárquica - Distância euclidiana, Single linkage. Fonte. Dados da pesquisa




Figura 14. Dendrograma gerado para aglomeração hierárquica - Distância euclidiana, com encadeamento “average linkage”. Fonte. Dados da pesquisa




Figura 15. Dendrograma gerado para aglomeração hierárquica - Distância euclidiana, com encadeamento “complete linkage”. Fonte. Dados da pesquisa

Não existe um "limite máximo" fixo na literatura para o número de observações para gerar um dendrograma, mas existe uma limitação prática na interpretação visual. Segundo Noble, o dendrograma é uma representação visual da hierarquia de agrupamento e é útil para bases pequenas e médias, facilitando a visualização de como clusters se formam e onde "cortar" a árvore para obter o número ideal de grupos. Para bases de dados com mais de 100 a 200 observações, como a que está em análise, a densidade visual do

dendrograma compromete severamente a sua legibilidade e, conseqüentemente, a sua principal utilidade interpretativa.

No entanto, dessas 3 opções de encadeamento testadas, a de “complete linkage” pareceu distinguir clusters um pouco mais que as outras. Segundo Fávero e Belfiore (2017), o encadeamento completo privilegia casos em que não exista considerável afastamento entre observações, o que é o caso dessa base. Assim prosseguiu-se a exploração gerando novos dendrogramas para a distância Manhattan (ou “city block”), na Figura 16 e, para a distância Chebichev, na Figura 17. ambas com encadeamento “complete linkage”. Em ambos casos, novamente ficou inelegível encontrar o número de clusters.




Figura 16. Dendrograma gerado para aglomeração hierárquica - Distância Manhattan (“city block”), com encadeamento “complete linkage”. Fonte. Dados da pesquisa




Figura 17. Dendrograma da aglomeração hierárquica - Distância Chebichev, com encademaneto “complete linkage”. Fonte. Dados da pesquisa.

Para bases de dados maiores, outras técnicas mais escaláveis são preferíveis, como o k-Means. A técnica k-means exige um parâmetro de número de clusters predefinidos. Como não se sabe esse número, primeiramente foi aplicado o método do cotovelo (“Elbow”), onde é feita a soma total dos quadrados dentro dos clusters (WCSS), para diversas quantidades de clusters, para ajudar a determinar o número ideal. Os resultados estão na Figura 18 e mostraram que não existe um ponto de cotovelo. Aplicou-se complementarmente a técnica da silhueta, na Figura 19. Segundo Fávero e Belfiore (2017), quanto mais próximo de 1 melhor. Pelos testes, está indicando cerca de 25 clusters, o que é difícil interpretar, logo nessa Etapa 1 foi decidido aplicar o k-means para 18 clusters. Na Tabela 2, são mostradas as quantidades de elementos de cada cluster. Nota-se que há mais de 9 clusters com poucos elementos.

Os testes estatísticos ANOVA foram conduzidos para verificar a significância das variáveis na clusterização e os resultados são apresentados na Tabela 3.




Figura 18. Método do Cotovelo (“elbow”) para Etapa 1. Fonte: Dados da pesquisa




Figura 19. Método da silhueta aplicado da Etapa 1 (com 21 variáveis). Fonte: Dados da pesquisa

Tabela 2. Quantidades de elementos por cluster, obtido na Etapa 1

Nro. Cluster	9	10	0	1	17	5	7	11	6	2	14	3	12	4	16	8	13	15
Qtde. itens	135	121	90	77	35	35	33	24	16	14	13	8	6	5	5	2	2	2

Fonte. Dados da pesquisa

De acordo com o critério do p-valor, a uma significância de 5%, tem-se que, com exceção da variável "vl_locfret_embarc", as demais foram relevantes na formação de pelo menos 1 dos clusters, pois p-valor <0,05. O teste F indica a relevância da variável na geração de pelo menos 1 dos clusters, ou seja, quanto maior esse valor, mais relevante é a variável

Os resultados dos clusters formados em 3D estão na Figura 20, considerando as variáveis de maior peso na soma total de gastos geral: "vl_divulg_ativ", "vl_pass_aerea_sigepa" e "vl_locfret_autom" e 20(b) com as 3 variáveis que o teste F forneceu como mais relevantes no Teste F: "vl_comb_semespec" "vl_tokens", "vl_comb_embarc". Apesar do resultado dos testes indicar que as variáveis contribuíram para geração dos agrupamentos, visualmente isso não foi perceptível e até desfavorável devido ao alto número de clusters. É um pouco menos pior distinguir clusters com as variáveis da Figura 20 do que com as da Figura 21, que forneceram maior valor de F.

A natureza dessa base mostra pontos muito próximos, sendo mais difícil distinguir em grupos de deputados por comportamento de gastos, em um primeiro momento, e, dados esses resultados, foi decidido seguir com outra abordagem.

Tabela 3: Valores do teste ANOVA das variáveis. Fonte. Dados da pesquisa

Parte 1			Parte 2		
Variável	F	p-valor	Variável	F	p-valor
vl_comb_semespec	362.5	0.000	vl_telefonia	43.3	0.000
vl_tokens	273.9	0.000	vl_taxi_ped_estac	39.5	0.000
vl_comb_embarc	152.3	0.000	vl_pass_aerea_sigepa	37.0	0.000
vl_cursos_eventos	135.2	0.000	vl_pis aérea reembolso	34.4	0.000
vl_servseguranca	129.9	0.000	vl_locfret_autom	33.5	0.000
vl_pass_ter_mar_flu	116.5	0.000	vl_comb_autom	32.5	0.000
vlassinaturas	106.6	0.000	vl_hospedagem	31.2	0.000
vl_locfret_aeronave	58.9	0.000	vl_manut_escritorio	21.1	0.000
vl_alimentacao	58.4	0.000	vl_comb_aeronaves	5.1	0.000
vl_divulg_ativ	52.1	0.000	vl_locfret_embarc	0.2	1.000
vl_pass_aerea_rpa	51.7	0.000			

Fonte: Dados da Pesquisa.




Figura 20. Gráfico 3D dos clusters formados na Etapa 1 com as 21 variáveis, mostrando as 3 principais variáveis no critério de montante total de gastos. Fonte. Dados da pesquisa




Figura 21. Gráfico 3D dos clusters formados na Etapa 1 com as 21 variáveis, mostrando as variáveis apontadas com maior F no teste ANOVA. Fonte. Dados da pesquisa

Na segunda etapa de exploração dos dados com métodos não supervisionados (designada “Etapa 2”), foi feita nova rodada de simulação de clusters com k-means, considerando apenas as variáveis de maior relevância em termos de valores monetários totais: “vl_divulg_ativ”, “vl_pass_aerea_sigepa”, “vl_locfret_autom”, “vl_manut_escritorio”, “vl_comb_autom” e “vl_hospedagem”: Os novos resultados do método de “elbow” e da silhueta estão na Figura 22 e na Figura 23 respectivamente. Notou-se que o gráfico de Elbow apresentou um ponto onde o ganho em termos de coesão dos *clusters* (redução do WCSS) não justifica mais o aumento da complexidade do modelo, em termos de número de clusters. Parece que entre 3 e 5 clusters seria suficiente. Pelo método da silhueta, também

mostra que 3 clusters seria o maior valor da métrica. Para a próxima etapa decidiu-se seguir com 5 clusters.

Para verificação de quais variáveis foram influentes na formação de pelo menos 1 dos clusters, novamente foi aplicado a ANOVA e verificou-se que todas as variáveis foram relevantes a nível de significância de 5%.




Figura 22. Método de “elbow”, para Etapa 2. Fonte: Dados da pesquisa.




Figura 23. Método da silhueta para Etapa 2. Fonte: Dados da pesquisa.

A variável associada aos gastos da rubrica “divulgação de atividades parlamentares” foi a mais relevante segundo a estatística F. A quantidade de elementos dos clusters foi maior, também ficou acima de 30 elementos, conforme mostrado na Tabela 5.

Tabela 4: Valores do teste ANOVA das variáveis da Etapa 2

Variável	F	p-valor
vl_divulg_ativ	859.0	0.000
vl_manut_escritorio	149.4	0.000
vl_pass_aerea_sigepa	149.4	0.000
vl_locfret_autom	133.9	0.000
vl_comb_autom	63.3	0.000
vl_hospedagem	19.8	0.000

Fonte. Dados da pesquisa

Tabela 5. Quantidade de elementos em cada cluster, na Etapa 2

Nro. Cluster	2	0	3	4	1
Qtde. elementos	191	131	123	99	79

Fonte. Dados da pesquisa

Como pode ser observado nas Figura 24 e Figura 25, a distribuição 3D dos registros com marcação do cluster associado mostra que, com menos variáveis utilizadas na técnica pode-se classificar em menos grupos e com divisão um pouco mais nítida, mostrando padrões de gastos similares num mesmo grupo. Há claramente uma influência da variável de divulgação de atividade parlamentar.

Observando a figura 24, nota-se que, se considerar a distribuição dos clusters com as variáveis "vl_manut_escritorio", "vl_locfret_autom" e "vl_comb_autom", a formação de clusters já fica menos definida.

Embora o agrupamento de parlamentares com base nos padrões de gastos tenha sido possível utilizando as três variáveis mais representativas (em termos de total de gastos de cada categoria), observa-se que as fronteiras entre os clusters são difusas. Isso ocorre devido à proximidade entre alguns pontos, o que resulta em sobreposição e dificulta a separação clara entre os grupos formados.

Observa-se que o Cluster 4 representa os parlamentares que mais desembolsaram, em termos de divulgação e passagens aéreas. Segundo a Figura 25, o cluster 3 parece representar os que menos despenderam. Esse Cluster 3 contém 123 parlamentares, em que 52% eram suplentes, o que faz sentido: eles ficam menos tempo e gastam menos, e 70% tem característica de não terem sido reeleitos. Pode ser que, por ser o primeiro mandato de muitos deles, seja importante cuidar da sua imagem e conduta perante os eleitores, no entanto isso é meramente uma hipótese.




Figura 24. Visualização dos clusters da Etapa 2, considerando as variáveis de gasto totais: "vl_divulg_ativ", "vl_locfret_autom" e "vl_pass_aerea_sigepa". Fonte. Dados da pesquisa




Figura 25. Visualização dos clusters da Etapa 2, considerando as variáveis de gastos totais: "vl_manut_escritorio", "vl_locfret_autom", "vl_comb_autom". Fonte. Dados da pesquisa

Na terceira e última etapa de exploração dos dados com métodos não supervisionados (designada “Etapa 3”), a proposta foi agora avaliar geração de clusters considerando a média de gastos de 6 categorias de cada deputado federal, considerando o número de meses que se observa atividade na base de gastos. Ex.: se um deputado trabalhou por 20 meses, todos os valores de gastos das 6 categorias foram divididos por 20. as categorias avaliadas serão as mesmas da etapa 2: divulgação da atividade parlamentar, passagem aérea - sigepa, locação ou fretamento de veículos automotores, manutenção de escritório de apoio à atividade parlamentar, combustíveis e lubrificantes - veículos automotores e hospedagem.

Na Figura 26, o método elbow mostrou que entre 3 e 5 clusters seriam suficientes para agrupar os parlamentares. Foi então decidido seguir com 5 clusters.

Dos 5 clusters formados, 4 deles tem mais de 80 elementos cada, salvo o “Cluster 4”, que contém apenas 3 elementos. De acordo com as Figuras 27 e 28, pela distribuição obtida, esses parlamentares parecem ser realmente “outliers” no comportamento médio de gastos, já que as médias são discrepantes em relação aos outros colegas. Segundo Fávero e Belfiore (2017), o método k-means é sensível à presença de outliers e a exclusão ou retenção de outliers depende dos objetivos da pesquisa e da natureza dos dados, e que outliers podem formar clusters pequenos ou até individuais, podendo ser excluídos ou analisados separadamente.

A relação dos indivíduos do Cluster 4 está na Tabela 7.




Figura 26. Método “elbow” para a Etapa 3. Fonte. Dados da pesquisa

Tabela 6. Valores do teste ANOVA das variáveis, na Etapa 3, com variáveis de valores médios de gastos de várias categorias.

Variável	F	p-valor
vl_divulg_ativ	506.84	0.00
vl_pass_aerea_sigepa	415.23	0.00
vl_manut_escritorio	295,22	0.00
vl_locfret_autom	272.8	0.00
vl_comb_autom	272.3	0.00
vl_hospedagem	68.9	0.00

Fonte: dados da pesquisa




Figura 27. Visualização dos clusters, considerando as 6 variáveis das categorias mais relevantes em termos de gasto médio: "vl_manut_escritorio", "vl_pass_aerea_sigepa" e "vl_loc_fret_autom". Fonte. Dados da pesquisa.




Figura 28. Visualização dos clusters, considerando as 6 variáveis das categorias mais relevantes em termos de gasto médio: "vl_divulg_ativ", "vl_locfret_autom", e "vl_pass_aerea_sigepa". Fonte. Dados da pesquisa.

Tabela 7. Características dos deputados presentes no Cluster 4, os “gastões”, da Etapa 3

Cluster	TxNomeParlamentar	sgUF	sgPartido	cat_reeleicao	cat_cargo_titusup
4	Robinson Faria	RN	PL	Nao_reeleito	Titular
4	Marcelo Queiroz	RJ	PP	Nao_reeleito	Titular
4	Osmar Terra	RS	MDB	Reeleito	Titular

Fonte. Dados da pesquisa

É importante ainda notar que as técnicas de clusterização não supervisionada possuem natureza exploratória e não preditiva, ou seja, os resultados obtidos nesta análise só valem para o conjunto de dados avaliado.

Uma das razões pela qual pode ser atribuído o insucesso em gerar clusters em algumas etapas é o baixo número de registros para essa análise, visto que os dados foram agrupados por deputado totalizando 623 registros apenas. Nesse caso, seria relevante trazer mais dados, como os de legislaturas anteriores.

Conclusão

A análise dos dados indica que os padrões de gastos entre parlamentares são bastante semelhantes quando se considera o conjunto completo das categorias. Utilizando técnicas não supervisionadas e focando nas variáveis com maior representatividade em termos de valor total, é possível identificar agrupamentos com base no comportamento geral de despesas, especialmente nos gastos com divulgação parlamentar. Essa categoria, em particular, merece atenção, pois as regras atuais de uso podem incentivar práticas que comprometem a boa gestão dos recursos públicos.

Como ideias de trabalhos futuros com essa base de dados ou nessa temática, pode-se considerar:

- 1) uso do método Kmeans++, com otimização dos centroides
- 2) efetuar análise de correspondência múltipla com as variáveis categóricas, incluindo a variável de cluster gerado na etapa dos métodos de clusterização.
- 3) aumentar o tamanho da base e continuar o estudo de clusterização considerando os perfis de gastos de legislaturas anteriores, com as devidas correções monetárias nos valores.

- 4) abordagem de análise da base granular de gastos, detectando anomalias, ou seja, dados desviam significativamente do comportamento esperado, através de métodos não supervisionados como Z-score, ou métodos como “Isolation forest”.
- 5) Análise dos CNPJ envolvidos nas notas fiscais do último trimestre dos anos de 2023 e 2024, para verificar se contém alguma irregularidade, ou se há favorecidos, principalmente nos gastos referentes à verba de divulgação de atividade parlamentar.
- 6) Uso da Lei de Newcomb-Benford para detecção de fraudes.

Agradecimento

Agradeço a meu esposo por todo suporte dado durante o período de realização do MBA e do trabalho de conclusão pelo apoio adicional no cuidado do nosso filho durante minha ausência para realizar as aulas e elaborar o trabalho. Agradeço também ao meu orientador, Prof. Eder Cassettari, por todo apoio durante a realização deste trabalho.

Referências

Câmara dos deputados Assessoria de imprensa. Guia para jornalistas sobre Cotas parlamentares. Disponível em
<<https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/cota-parlamentar>>. Acesso em 31 de maio de 2025.

Câmara dos Deputados. Assessoria de imprensa. Guia para jornalistas sobre a Câmara dos deputados. Disponível em
<<https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/camara-dos-deputados>>. Acesso em 16 de junho de 2025.

Câmara dos deputados. Cota para o Exercício da Atividade Parlamentar (Ceap). Disponível em
<<https://www2.camara.leg.br/a-camara/documentos-e-pesquisa/arquivo/sites-tematicos/57a-legislatura/no-exercicio-do-mandato/cota-para-o-exercicio-da-atividade-parlamentar-ceap>>. Acessado em 2 de setembro de 2025.

Câmara dos deputados. Dados abertos. Sessão Despesas pela Cota para Exercício da Atividade Parlamentar. Disponível em
<<https://dadosabertos.camara.leg.br/swagger/api.html?tab=staticfile>>. Primeiro acesso em 10 de maio de 2025 e segundo acesso em 2 de setembro de 2025.

Câmara dos deputados. Gastos parlamentares. Disponível em
<<https://www.camara.leg.br/transparencia/gastos-parlamentares/>>. Acesso em 2 de maio de 2025.

Câmara dos deputados. Perguntas frequentes sobre deputados e seus mandatos. Disponível em <

https://www2.camara.leg.br/transparencia/acesso-a-informacao/copy_of_perguntas-frequentes/deputados>. Acesso em 2 de setembro de 2025.

Câmara dos deputados. Portaria Nº 228, de 18/06/2014. Disponível em <<https://www2.camara.leg.br/legin/int/portar/2014/portaria-228-18-junho-2014-779144-publicacaooriginal-144692-cd-dg.html>>. Acesso em 16 de junho de 2025.

Câmara dos deputados. Resultado dos deputados eleitos (titulares) para a 57ª legislatura. Disponível em

<<https://www.camara.leg.br/internet/agencia/infograficos-html5/tabelasEleicoes/deputados-eleitos-estado/index.html>>. Acesso em 20 de julho de 2025.

Câmara dos deputados. Resultado dos deputados reeleitos para a 57ª legislatura. Disponível em

<<https://www.camara.leg.br/noticias/912220-reeleicao-na-camara-alcanca-57-veja-quais-deputados-foram-reeleitos/>>. Acesso em 5 de julho de 2025.

Câmara dos deputados. Significado das colunas da base de gastos parlamentares. <<https://dadosabertos.camara.leg.br/howtouse/2023-12-26-dados-ceap.html>>. Acesso em 2 de maio de 2025.

Câmara dos Deputados. Assessoria de imprensa sobre recesso. Disponível em <<https://www2.camara.leg.br/comunicacao/assessoria-de-imprensa/guia-para-jornalistas/recesso-dos-deputados>>. Acesso em 19 de julho de 2025.

Fávero, L. P.; Belfiore, P. Manual de análise dados: estatística e modelagem multivariada com Excel, SPSS e Stata. Rio de Janeiro: Elsevier, 2017. Acesso em 7 junho de 2025.

Lemos, L.; Joseph, R. 2010. Parliamentarians' Expenses Recent Reforms: a briefing on Australia, Canada, United Kingdom and Brazil. Global Economic Governance Programme-GEG Working Paper 2010/57. Disponível em <https://www.geg.ox.ac.uk/sites/default/files/Lemos%20Joseph_GEG%20WP%202010_57.pdf>. Acesso em 15 de junho de 2025.

Noble, J. Como funciona o agrupamento hierárquico. Disponível em <<https://www.ibm.com/br-pt/think/topics/hierarchical-clustering>> Acesso em 17 de agosto de 2025.

Silva, C. F.; Santos, E. M. F.; Chaves, M. C.; Vaz, W; Balaniuk, R. Dados abertos: uma estratégia para o aumento da transparência e modernização da gestão pública. Revista do TCU, Brasília, n. 131, p. p. 22–29, 2014. Disponível em: <<https://revista.tcu.gov.br/ojs/index.php/RTCU/article/view/59>> Acesso em 14 de junho de 2025.

Tribunal de Contas da União. 2018. Relatório sistêmico sobre Transparência Pública. Disponível em: https://portal.tcu.gov.br/data/files/16/63/C5/6F/46A1F6107AD96FE6F18818A8/Fisc_Transparencia.pdf. Acesso em 15 de junho de 2025.

Tribunal de Contas da União. 2019. Acórdão 3048/2019 - Plenário. Disponível em < <https://pesquisa.apps.tcu.gov.br//acordao-completo/Ac%25C3%25B3rd%25C3%25A3o%25203048%252F2019%2520/%2520/DTRELEVANCIA%2520desc%252C%2520NUMACORDA%2520OINT%2520desc/0/%2520>>. Acessado em 30 de junho de 2025.